

Step-by-Step: Evaluation Metrics for Regression Task

Lê Hữu Phước Dương Đình Thắng Đình Quang Vinh

I. Dẫn nhập

“Mọi người đều là thiên tài. Nhưng nếu bạn đánh giá một con cá qua khả năng trèo cây nó sẽ sống cả đời mà tin rằng mình ngu ngốc” – là một câu nói vô cùng phổ biến được người ta truyền miệng trong những năm cuối thế kỷ 20, nhằm châm biếm sự máy móc, chưa phù hợp trong việc đánh giá học sinh của hệ thống giáo dục lúc bấy giờ. Thực vậy, không chỉ trong sự nghiệp “trồng người” mà ở bất kỳ lĩnh vực nào, việc tìm được một thước đo, phương pháp đánh giá công bằng, chuẩn xác đối với lĩnh vực đó là vô cùng quan trọng, mang tính quyết định đến những sự phát triển sau này.



Hình 1: Quá trình đánh giá chỉ có thể phản ánh đúng bản chất của đối tượng khi được dựa trên các metrics phù hợp. Ngược lại, nó sẽ trở thành một phép thử vô nghĩa.

Nguyên tắc này được thể hiện một cách đặc biệt rõ ràng trong các bài toán học máy, mà một ví dụ điển hình chính là các **Regression Task** (tạm dịch: bài toán hồi quy). Với Regression, câu hỏi không chỉ là đúng hay sai, mà là “sai bao nhiêu?”, và chính cách chúng ta định nghĩa và đo lường sự sai lệch này thông qua các **Evaluation Metrics** (tạm dịch: thước đo đánh giá) sẽ quyết định hoàn toàn hướng đi và chất lượng của mô hình.

Mục lục

I.	Dẫn nhập	1
II.	Một số Evaluation Metrics có trong Regression Task	4
II.1.	Tổng quan	4
II.2.	R^2 Score	8
II.3.	Mean Absolute Error	10
II.4.	Mean Square Error	11
II.5.	Mean Squared Logarithmic Error	12
II.6.	Mean Absolute Percentage Error	13
II.7.	Median Absolute Error	15
III.	Thực hành	16
III.1.	Mô tả bài toán	16
III.2.	Lời giải	17
IV.	Câu hỏi trắc nghiệm	22
V.	Tài liệu tham khảo	24
	Phụ lục	25

Để hỗ trợ cho xuyên suốt thời gian đọc bài này, sau đây là bảng thuật ngữ ghi chú những nội dung cần chú ý trong bài “Step-by-Step: Evaluation Metrics for Regression Task”.

Bảng chú thích thuật ngữ

Thuật ngữ	Giải thích
Regression / Regression Task (tác vụ/bài toán hồi quy)	Bài toán học máy có giám sát nhằm dự đoán một giá trị số liên tục dựa trên mối quan hệ đã học từ dữ liệu huấn luyện.
Evaluation Metrics (thước đo đánh giá)	Các công cụ toán học để định lượng hiệu quả của mô hình bằng cách đo lường sự khác biệt giữa dự đoán và thực tế.
Dependent Variable (biến phụ thuộc)	Đầu ra hay kết quả mà ta muốn dự đoán, ký hiệu là y .
Independent Variables (biến độc lập)	Đầu vào hay các đặc trưng được sử dụng để đưa ra dự đoán, ký hiệu là x .
Residual / Error (sai số/phần dư)	Sự chênh lệch giữa giá trị thực tế và giá trị dự đoán: $e_i = y_i - \hat{y}_i$.
SST (Total Sum of Squares)	Tổng bình phương sai số toàn phần, đo lường sự biến thiên tổng thể của dữ liệu: $\sum_{i=1}^n (y_i - \bar{y})^2$.
SSR (Sum of Squared Residuals)	Tổng bình phương sai số phần dư, đo lường phần biến thiên không được giải thích bởi mô hình: $\sum_{i=1}^n (y_i - \hat{y}_i)^2$.
L1-Norm Loss	Tổng các sai số tuyệt đối, cơ sở toán học của MAE: $\sum_{i=1}^n y_i - \hat{y}_i $.
Scale-independent (không phụ thuộc thang đo)	Tính chất của một metric khi kết quả không bị ảnh hưởng bởi đơn vị đo lường của dữ liệu gốc.
Robust to outliers (kháng cự outliers)	Khả năng của một metric không bị ảnh hưởng mạnh bởi các giá trị ngoại lai bất thường.
Under-predicted estimate (dự đoán thấp)	Trường hợp mô hình dự đoán giá trị nhỏ hơn thực tế ($\hat{y}_i < y_i$).
Over-predicted estimate (dự đoán cao)	Trường hợp mô hình dự đoán giá trị lớn hơn thực tế ($\hat{y}_i > y_i$).
Goodness of fit (mức độ phù hợp)	Khả năng của mô hình trong việc khớp với dữ liệu quan sát được.
Proportion of variance (tỷ lệ phương sai)	Phần trăm sự biến thiên của biến phụ thuộc được giải thích bởi mô hình.
Naive model (mô hình ngây thơ)	Mô hình đơn giản trả về giá trị trung bình $\bar{y}$ cho mọi dự đoán.
Outliers (giá trị ngoại lai)	Những điểm dữ liệu có giá trị bất thường, nằm xa khỏi phần lớn các điểm khác trong tập dữ liệu.


II. Một số Evaluation Metrics có trong Regression Task

II.1. Tổng quan

Regression (tạm dịch: hồi quy), hay còn gọi là regression analysis, là một bài toán trong hệ **supervised learning** (tạm dịch: học có giám sát). Mục tiêu của hồi quy là ước lượng hoặc dự đoán một giá trị số liên tục, chẳng hạn như giá cổ phiếu trong tương lai gần hoặc nhiệt độ vào ngày mai, dựa trên mối quan hệ đã học được từ dữ liệu huấn luyện.

Về cơ bản, bài toán hồi quy tìm cách “mô hình hóa” mối quan hệ nhân quả hoặc sự tương quan giữa các yếu tố khác nhau. Để thực hiện điều này, bài toán được xây dựng dựa trên hai loại biến chính:

- **Dependent Variable** (tạm dịch: biến phụ thuộc): là đầu ra, kết quả hay các giá trị mà ta muốn dự đoán, ví dụ như nhiệt độ sau vài giờ, giá nhà sau vài tháng,...
- **Independent Variables** (tạm dịch: các biến độc lập): là đầu vào, đặc trưng hay các yếu tố được sử dụng để đưa ra dự đoán, ví dụ như thời gian, khối lượng giao dịch, độ ẩm,...



Hình 2: Mô tả về bài toán Regression và Regression Line.

Quá trình hồi quy là quá trình học mối quan hệ giữa các biến độc lập đối với biến phụ thuộc để đưa ra một mô hình dưới dạng một hàm số toán học $y = f(x)$. Sao cho, với cùng một hoặc tập điểm dữ liệu đầu vào x , mô hình hồi quy $f(x)$ sẽ có khả năng xấp xỉ giá trị thực tế y một cách tốt nhất.


Trước đó, để tiện theo dõi và hỗ trợ quá trình đọc, sau đây là bảng ký hiệu toán học được sử dụng xuyên suốt bài viết:

Bảng Ký hiệu Toán học

Ký hiệu	Ý nghĩa
n	Tổng số mẫu dữ liệu trong tập huấn luyện hoặc kiểm tra.
(x_i, y_i)	mẫu thứ i -th, đầu vào x_i , nhãn y_i .
X	tập giá trị các đặc trưng đầu vào.
$\hat{y}_i$	Giá trị dự đoán của mô hình cho mẫu thứ i -th.
$\bar{y}$	Giá trị trung bình của tất cả các giá trị thực tế: $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$.
e_i	Sai số tại mẫu thứ i : $e_i = y_i - \hat{y}_i$.
F	Đại diện cho metric hay chỉ số đánh giá mức độ sai lệch của sai số.
SST	Total Sum of Squares hay Tổng bình phương sai số toàn phần $\sum_{i=1}^n (y_i - \bar{y})^2$.
SSR	Sum of Squared Residuals hay Tổng bình phương sai số phần dư: $\sum_{i=1}^n (y_i - \hat{y}_i)^2$.
MAE	Mean Absolute Error hay Sai số Tuyệt đối Trung bình: $\frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $.
MSE	Mean Squared Error hay Sai số Tuyệt đối Bình phương: $\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$.
RMSE	Root Mean Squared Error hay Căn bậc hai của Sai số Bình phương Trung bình: $\sqrt{\text{MSE}}$.
MSLE	Mean Squared Logarithmic Error, Sai số Logarithm Bình Phương.
MAPE	Mean Absolute Percentage Error, Sai số Phần trăm Tuyệt đối Trung bình.
MedAE	Median Absolute Error, Sai số Tuyệt đối Trung Vị.
$\log_e(x)$	Logarithm tự nhiên (natural logarithm) của x .
ϵ	Hằng số dương rất nhỏ để tránh chia cho 0.
$\max(a, b)$	Hàm trả về giá trị lớn hơn giữa a và b .
median	Hàm tính giá trị trung vị của một dãy số.
$f(x)$	Mô hình hồi quy, hàm ánh xạ từ đầu vào x sang đầu ra y .

II.1.1. Phát biểu bài toán

Khi nói về các bài toán Regression, có một vài metrics đã trở thành công cụ đo lường không thể thiếu, phổ biến nhất là **Mean Squared Error** (MSE), **Root Mean Squared Error** (RMSE), và **Mean Absolute Error** (MAE). Các metrics này đều có chung mục đích là đo lường mức độ sai lệch giữa giá trị dự đoán và giá trị thực tế, nhưng được thực hiện và mang nhiều ý nghĩa khác nhau. Chúng là những công cụ toán học cung cấp bằng chứng xác thực để định lượng độ hiệu quả của mô hình. Trên thực tế, quá trình này thường đòi hỏi việc so sánh hiệu năng giữa nhiều mô hình khác nhau, như được minh họa trong Hình 3.



Hình 3: Tùy thuộc vào mục đích, các metrics có thể được sử dụng để đánh giá hiệu năng giữa các mô hình với nhau hoặc đánh giá trên nhiều tập dữ liệu khác nhau.


Giả định rằng ta mong muốn dự đoán doanh thu cho một cửa hàng bánh bằng cách huấn luyện một mô hình hồi quy. Khi mô hình đã sẵn sàng, ta sẽ tự hỏi rằng: “Liệu dự đoán này có đủ tin cậy không?”. Nỗi lo này hoàn toàn có cơ sở, bởi chỉ một sai lệch nhỏ cũng đủ gây xáo trộn cho việc chuẩn bị nguyên liệu và ảnh hưởng tới doanh thu. Để trả lời cho câu hỏi này, tiếp sau đây, chúng ta sẽ cùng nhau áp dụng các metrics hồi quy phổ biến để đo lường và đưa ra các đánh giá và kết luận về hiệu quả của mô hình dự đoán doanh thu cho cửa hàng bánh.

II.1.2. Step-by-step

Áp dụng với ví dụ bài toán dự đoán doanh thu cửa hàng bánh ở phần dẫn nhập, ta có thể nhận thấy được:

- Biến phụ thuộc (y) là doanh thu thực tế của một ngày. Đây là giá trị mục tiêu mà chúng ta muốn mô hình có thể dự đoán được.
- Các biến độc lập (x) là tập hợp các thông tin đầu vào như thời gian, thời tiết, và sự kiện đặc biệt.

Cụ thể, mô hình hồi quy $f(x)$ sẽ cố gắng học mối quan hệ từ các thông tin đầu vào x và doanh thu thực tế (y) để sau đó đưa ra doanh thu dự đoán của một ngày mới $\hat{y}$. Vậy thì, làm sao để biết được giá trị $\hat{y}$ có đáng tin cậy hay không? Nói cách khác, làm sao để xác định được độ hiệu quả của mô hình hồi quy $f(x)$?



Hình 4: Mô hình hóa bài toán dự đoán doanh thu cửa hàng bánh.

Ta có một tập dữ liệu về doanh thu cửa hàng bánh gồm n cặp giá trị (x_i, y_i) , với:

- x_i là một vector chứa các giá trị của biến độc lập hay các **features** (đặc trưng) thông tin của ngày thứ i -th cần dự đoán.
- y_i là giá trị thực tế của biến phụ thuộc hay kết quả doanh thu mục tiêu tương ứng với đầu vào x_i .

Sau khi thực hiện quá trình hồi quy, ta thu được một mô hình hồi quy gọi là $f(x)$. Khi đó, nếu đưa vào $f(x)$ một bộ dữ liệu có tập giá trị đầu vào:

$$X = \{x_1, x_2, x_3, \dots, x_n\},$$

kết quả sẽ thu được một tập kết quả dự đoán tương ứng:


$$\hat{y} = \{\hat{y}_1, \hat{y}_2, \hat{y}_3, \dots, \hat{y}_n\}, \quad \text{với } \hat{y} = f(x_i),$$

Lúc này, với cùng một tập giá trị đầu vào X , hiện hữu 2 tập kết quả thực tế y và kết quả dự đoán $\hat{y}$ vừa tính được.

Như đã đề cập ở phần **I.1**, cách trực quan nhất để đánh giá hiệu năng của mô hình là thiết lập **Evaluation Metrics** giữa kết quả thực tế y và kết quả dự đoán $\hat{y}$. Ở đây, ta định nghĩa **score** (tạm dịch: giá trị cụ thể) cho một metric bất kỳ:

$$\text{score} = F(e), \quad \text{với } e = \{e_1, e_2, \dots, e_n\},$$

trong đó, F là hàm metric cụ thể, nhận vào tất cả các sai số $e = \{e_1, e_2, \dots, e_n\}$ với mỗi sai số được tính bằng $e_i = y_i - \hat{y}_i$.



Hình 5: Với hai tập giá trị y và $\hat{y}$, ta thu được tập giá sai số e là sự sai lệch giữa hai tập giá trị.

Kết quả của hàm F là một chỉ số duy nhất, gọi là **score**. **Score** đóng vai trò là thước đo cuối cùng, phản ánh hiệu suất tổng thể của mô hình hồi quy trên toàn bộ tập dữ liệu X .

Thế nhưng, hàm metric F này có rất nhiều công thức toán học khác nhau và mỗi cái lại sử dụng một “lăng kính” riêng để đánh giá sự khác biệt giữa thực tế và dự đoán. Vì vậy, trong phần tiếp theo, chúng ta sẽ đi sâu vào định nghĩa, công thức, và ý nghĩa của một số metrics phổ biến nhất được sử dụng trong các bài toán hồi quy để lựa chọn được metric phù hợp nhất cho từng bài toán cụ thể.

II.2. R^2 Score

Thay vì tập trung vào câu hỏi “Mức độ sai lệch của mô hình là bao nhiêu?”, R^2 đánh giá khả năng học mối quan hệ giữa các biến đầu vào và biến phụ thuộc. Nó trả lời cho câu hỏi “Mô hình nắm bắt được bao nhiêu phần quy luật của dữ liệu hiện tại?”.

Câu trả lời này được thể hiện qua **proportion of variance** (tạm dịch: tỷ lệ phương sai) của biến phụ thuộc y mà mô hình có thể giải thích được thông qua các biến độc lập x . R^2 cung cấp một trị số đánh giá **goodness of fit** (tạm dịch: mức độ phù hợp) của **Regression Line** (tạm dịch: đường hồi quy), cho thấy mô hình có thể dự đoán được các mẫu dữ liệu mới tốt đến đâu, dựa trên tỷ lệ phương sai mà nó giải thích được.

Từ tập giá trị $\hat{y}$ và y ở phần II.1 trước đó, nếu $\hat{y}_i$ là giá trị dự đoán của mẫu thứ i -th và y_i là giá trị thực tế tương ứng, trên toàn tập dữ liệu gồm n mẫu, R^2 được ước tính như sau:

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$


,trong đó:

- $\bar{y}$ là giá trị trung bình của tập giá trị chính xác, với $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$.
- $\sum_{i=1}^n (y_i - \bar{y})^2$ là **Total Sum of Squares - SST** (tổng bình phương sai số toàn phần), đại diện cho tổng sự biến thiên của biến phụ thuộc y trong tập dữ liệu.
- $\sum_{i=1}^n (y_i - \hat{y}_i)^2$ là **Sum of Squared Residuals - SSR** (tổng bình phương sai số của phần dư), đại diện cho một phần sự biến thiên không giải thích được bởi mô hình.

Ý tưởng cốt lõi của metric này là so sánh mô hình mong muốn dự đoán $f(x)$ với một mô hình ngây thơ được định nghĩa:

- **Naive model** (tạm dịch: Mô hình ngây thơ): là một mô hình mà với bất kỳ giá trị đầu vào nào, đều sẽ trả về giá trị trung bình $\bar{y}$ của tất cả các điểm dữ liệu đã biết.
- **Mô hình dự đoán $f(x)$** : là đường hồi quy hay mô hình hồi quy được xây dựng từ quá trình học quan hệ của các biến độc lập so với biến phụ thuộc.

💡 **Ví dụ:** Trong bối cảnh dự đoán doanh thu cho cửa hàng bánh, một mô hình với R^2 score = 0.8 có nghĩa là 80% sự chênh lệch về doanh thu giữa các ngày có thể được giải thích bởi các yếu tố đầu vào mà mô hình đã học, như thời tiết, các ngày lễ, hay chương trình khuyến mãi. 20% còn lại của sự biến động là do các yếu tố khác mà mô hình chưa nắm bắt được.



Hình 6: Các đại lượng SST, SSR, Regression Line và Mean of actual value.

Từ đó, bằng cách so sánh mô hình dự đoán với mô hình ngây thơ $\bar{y}$, R^2 được thiết lập, trả lời cho câu hỏi mô hình đã nắm bắt được bao nhiêu phần của quy luật dữ liệu.

Bảng 1: Diễn giải các giá trị của R^2 Score

Giá trị R^2	Quan hệ SSR-SST	Ý nghĩa
$R^2 = 1$	$SSR = 0$	Mô hình hoàn hảo: $y_i = \hat{y}_i$ trên mọi điểm dữ liệu. Đường hồi quy đi qua tất cả các điểm thực tế.
$0 < R^2 < 1$	$0 < SSR < SST$	Trường hợp phổ biến nhất. Mô hình giải thích được một phần sự biến thiên của dữ liệu. Ví dụ: $R^2 = 0.8$ nghĩa là giải thích được 80% sự biến thiên.
$R^2 = 0$	$SSR = SST$	Mô hình không mang lại giá trị gì, hiệu quả ngang với mô hình ngây thơ (dự đoán bằng giá trị trung bình).
$R^2 < 0$	$SSR > SST$	Mô hình hoạt động rất tệ, còn kém hơn cả mô hình ngây thơ. Có thể do mô hình được xây dựng hoặc áp dụng sai cách.

⚠ Lưu ý: R^2 Score tồn đọng một số điểm bất cập trong chính cơ chế của nó khiến nó ít được dùng riêng lẻ để đánh giá:

- R^2 luôn tăng hoặc giữ nguyên khi các biến độc lập mới được thêm vào mô hình mà không cần biết các biến này có ý nghĩa hay có quan trọng với mô hình hay không.
- Khó để nhận biết được biến độc lập nào có quan hệ nhân quả đối với biến phụ thuộc vì R^2 Score chỉ giải thích sự ảnh hưởng của các biến với nhau.

II.3. Mean Absolute Error

Mean Absolute Error (MAE), tạm dịch là Sai số Tuyệt đối Trung bình, đo lường **sự khác biệt trung bình về độ lớn** giữa kết quả dự đoán và kết quả thực tế, cho biết khoảng cách giữa các điểm dữ liệu thực tế so với đường hồi quy. Kết quả của MAE chính là tổng các sai số tuyệt đối (**L1-Norm Loss**) được chuẩn hóa về mức trung bình bằng cách chia cho tổng số lượng mẫu toàn tập dữ liệu.

Nếu $\hat{y}_i$ là giá trị dự đoán của mẫu thứ i -th và y_i là giá trị thực tế tương ứng, công thức của sai số tuyệt đối trung bình MAE được định nghĩa là:


$$\text{MAE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} |y_i - \hat{y}_i|$$

trong đó,

- $|y_i - \hat{y}_i|$ là sai số tuyệt đối tại mẫu dữ liệu thứ i -th.
- n_{samples} là tổng số mẫu có trong tập dữ liệu ban đầu.

Kết quả của MAE là một giá trị trong khoảng $[0, +\infty)$, được diễn giải như sau:

- Giá trị MAE càng tiến gần đến 0, mô hình càng được xem là chính xác. Một điểm số $\text{MAE} = 0$ thể hiện một mô hình dự đoán hoàn hảo, không có sai số.
- Giá trị MAE không có giới hạn trên. Điều này là do sai số của một dự đoán riêng lẻ có thể lớn tùy ý, và do đó, sai số trung bình cũng có thể nhận những giá trị rất lớn, phản ánh hiệu năng kém của mô hình.



Hình 7: Đồ thị trực quan hóa công thức của MAE trên trục tọa độ.

💡 **Ví dụ:** Sau khi áp dụng mô hình dự đoán trên dữ liệu doanh thu của cửa hàng bánh trong một tháng, ta tính được $MAE = 800.000$ VNĐ. Kết quả này cung cấp một thông tin kinh doanh rõ ràng: “Trung bình mỗi ngày, dự đoán của mô hình lệch khỏi doanh thu thực tế là 800.000 VNĐ”. Dựa vào đó, người quản lý có thể cân nhắc một khoản dự phòng rủi ro cho các kế hoạch tài chính của mình.

II.4. Mean Square Error

Mean Squared Error (MSE), tạm dịch là Sai số Bình Phương Trung Bình, là một metric hồi quy phổ biến tính toán **trung bình của bình phương các sai số** $(y_i - \hat{y}_i)^2$. Do cơ chế bình phương, MSE xử phạt rất nặng những sai số lớn. Điều này khiến nó cực kỳ nhạy cảm với outliers (các điểm dữ liệu ngoại lai) chỉ một vài điểm có sai số khổng lồ cũng đủ làm giá trị MSE tăng vọt, từ đó “kéo” mô hình về phía chúng và có thể làm giảm hiệu năng trên các điểm dữ liệu thông thường.

Tương tự như MAE, nếu $\hat{y}_i$ là giá trị dự đoán của mẫu thứ i -th và y_i là giá trị thực tế tương ứng, công thức của sai số bình phương trung bình MSE được định nghĩa là:


$$MSE(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} (y_i - \hat{y}_i)^2$$

trong đó,

- $(y_i - \hat{y}_i)^2$ là bình phương các sai số này tại mẫu dữ liệu thứ i -th.
- n_{samples} là tổng số mẫu có trong tập dữ liệu ban đầu.

Kết quả của MSE cũng là một giá trị trong khoảng $[0, +\infty)$, được diễn giải như sau:

- Giá trị MSE càng tiến gần đến 0, mô hình càng được xem là chính xác. Một điểm số $MSE = 0$ thể hiện một mô hình dự đoán hoàn hảo.
- Tương tự như MAE, giá trị MSE không có giới hạn trên vì sai số của một dự đoán riêng lẻ có thể lớn tùy ý.



Hình 8: Đồ thị trực quan hóa sự khác biệt về công thức của MAE, MSE và RMSE trên trục tọa độ.

💡 **Ví dụ:** Giả sử trong bài toán dự đoán doanh thu cửa hàng bánh, mô hình có sai lệch 2.000.000 trong ngày thường và 10.000.000 trong ngày lễ. Khi tính MSE, sai số 2.000.000 được bình phương thành 4.000.000, trong khi sai số 10.000.000 bị bình phương lên tới 100.000.000. Mức “phạt” chênh lệch khổng lồ này buộc mô hình phải học cách tránh lặp lại những sai lầm nghiêm trọng, dù chúng hiếm khi xảy ra.

⚠️ **Lưu ý:** Một hạn chế lớn của MSE là đơn vị của nó là bình phương của đơn vị gốc. Điều này khiến cho giá trị của nó khó được diễn giải một cách trực quan vì không còn nằm trên cùng một thang đo với biến mục tiêu ban đầu.

Để giải quyết vấn đề của MSE về sai lệch đơn vị, **Root Mean Squared Error** (hay RMSE), Căn bậc hai của Sai số Bình phương Trung Bình, đã được giới thiệu để thực hiện phép tính tương tự MSE nhưng lấy căn bậc hai ở bước cuối để kết quả được đưa về cùng đơn vị với biến mục tiêu.

$$\text{RMSE}(y, \hat{y}) = \sqrt{\frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} (y_i - \hat{y}_i)^2}$$

II.5. Mean Squared Logarithmic Error

Mean Squared Logarithmic Error (MSLE), tạm dịch là Sai số Logarit Bình phương Trung bình là một biến thể của MSE, được thiết kế cho các bài toán hồi quy có dải giá trị rộng hoặc tăng theo cấp số mũ (ví dụ: dự báo doanh thu qua nhiều năm). Đặc tính cốt lõi của MSLE là nó tính toán sai số trên logarit tự nhiên của giá trị thực tế và giá trị dự đoán. Cách tiếp cận này mang lại hai lợi ích quan trọng:

- Thay vì tính toán trên giá trị gốc, nó chuyển trọng tâm đánh giá từ sai số tuyệt đối sang sai số tương đối, giúp đánh giá công bằng hơn khi dữ liệu có sự chênh lệch lớn về độ lớn.
- MSLE “trừng phạt” các trường hợp **under-predicted estimate** (dự đoán thấp hơn thực tế) nặng nề hơn so với các trường hợp **over-predicted estimate** (dự đoán cao hơn thực tế). Điều này là vô cùng quan trọng trong các bài toán mà việc dự đoán thiếu là gây ra rủi ro nghiêm trọng. Ví dụ: dự báo thiếu hàng tồn kho, dự báo sai lệch độ bùng phát dịch bệnh, ...

Nếu $\hat{y}_i$ là giá trị dự đoán của mẫu thứ i -th và y_i là giá trị thực tế tương ứng, công thức của sai số logarit bình phương trung bình MSLE được định nghĩa là:


$$\text{MSLE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} (\log_e(1 + y_i) - \log_e(1 + \hat{y}_i))^2$$

trong đó,

- $\log(1 + y_i)$ là logarit tự nhiên của giá trị thực tế tại mẫu dữ liệu i -th. Việc cộng thêm 1 là để đảm bảo rằng kết quả của phép lấy logarit này sẽ không rơi vào trường hợp bằng 0.
- tương ứng, $\log(1 + \hat{y}_i)$ là logarit tự nhiên của giá trị mà mô hình dự đoán được.
- $(\log(1 + y_i) - \log(1 + \hat{y}_i))^2$ là bình phương của sai số trên thang đo logarit.
- n_{samples} là tổng số mẫu có trong tập dữ liệu.

Do chỉ thay đổi từ sai số tuyệt đối sang sai số tương đối, kết quả của phép tính MLSE vẫn là một giá trị trong khoảng $[0, +\infty)$, được diễn giải như sau:

- Giá trị MLSE càng tiến gần đến 0, mô hình càng được xem là chính xác.
- Kết quả do mô hình dự đoán vẫn là tùy biến dẫn đến chênh lệch giữa logarit dự đoán và thực tế có thể lớn hoặc nhỏ tùy ý. Do đó, kết quả của metric MLSE không có cận trên và có thể tiến tới vô cùng ở điều kiện thích hợp.



Hình 9: Đồ thị trực quan hóa công thức của MSLE trên trục tọa độ.

💡 **Ví dụ:** Giả sử trong bài toán dự đoán doanh thu từ bánh kem (thực tế là 2.000.000 VNĐ), ta có hai sai lầm cùng mức chênh lệch tuyệt đối là 500.000 VNĐ. Dưới góc nhìn của MSLE, tác động của hai sai lầm này rất khác biệt: việc dự đoán thừa (dự đoán 2.500.000 VNĐ) sẽ nhận một mức phạt sai số thấp, trong khi đó việc dự đoán thiếu (dự đoán 1.500.000 VNĐ) lại bị phạt nặng hơn đáng kể.

II.6. Mean Absolute Percentage Error

Mean Absolute Percentage Error (MAPE), tạm dịch là Sai số Phần trăm Tuyệt đối Trung bình, còn được biết đến với tên gọi **Mean Absolute Percentage Deviation** (MAPD), là một metric hồi quy tập trung vào sai số tương đối, bằng cách tính toán sai số trung bình dưới dạng tỷ lệ phần trăm của giá trị thực tế.


Ưu điểm lớn nhất của cách tiếp cận này là kết quả của MAPE trở nên scale-independent (không phụ thuộc vào thang đo của dữ liệu). Điều này không chỉ giúp việc giải thích kết quả (ví dụ: “mô hình sai trung bình 15%”) trở nên rất trực quan cho các bên liên quan, mà còn cho phép so sánh công bằng hiệu năng của mô hình trên các điểm dữ liệu có độ lớn chênh lệch nhau (ví dụ: doanh thu của sản phẩm bán chạy và sản phẩm bán chậm).

Nếu $\hat{y}_i$ là giá trị dự đoán của mẫu thứ i -th và y_i là giá trị thực tế tương ứng, công thức của sai số phần trăm tuyệt đối trung bình MAPE được định nghĩa là:

$$\text{MAPE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} \frac{|y_i - \hat{y}_i|}{\max(\epsilon, |y_i|)}$$

trong đó,

- $\frac{|y_i - \hat{y}_i|}{\max(\epsilon, |y_i|)}$ là sai số phần trăm tuyệt đối tại mẫu dữ liệu thứ i -th.
- ϵ là một hằng số thực dương được chọn trước ngẫu nhiên có giá trị rất nhỏ (ví dụ: 10^{-8}) được thêm vào để tránh lỗi chia cho 0 khi giá trị thực tế y_i bằng 0.
- $\max(\epsilon, |y_i|)$ là một hàm trả về giá trị lớn hơn giữa ϵ và $|y_i|$. Thao tác này đảm bảo mẫu số của phép chia không bao giờ bằng 0.
- n_{samples} là tổng số mẫu có trong tập dữ liệu.



Hình 10: Đồ thị trực quan hóa công thức của MAPE trên trục tọa độ.

Kết quả của MAPE là một giá trị trong khoảng $[0, +\infty)$, được diễn giải như sau:

- Giá trị MAPE càng tiến gần đến 0%, sai lệch của dự đoán với thực tế gần như không có, mô hình càng được xem là chính xác.
- Ngay cả khi đã có ϵ , các giá trị sai số có thể sẽ rất lớn nếu y_i có giá trị gần bằng 0, dẫn tới MAPE cũng rất lớn, không có giới hạn trên và có thể tiến tới vô cùng.

💡 **Ví dụ:** Một mô hình dự báo doanh thu của hàng bánh cho hai nhóm sản phẩm khác nhau: nhóm bánh mì có doanh thu thực tế 10 triệu VNĐ nhưng dự đoán 9.000.000 (sai số 1.000.000), trong khi nhóm bánh kem có thực tế 1.000.000 nhưng dự đoán 800.000 (sai số 200.000).

Thoạt nhìn, ta có thể nghĩ mô hình dự đoán bánh kem tốt hơn vì MAE nhỏ hơn. Tuy nhiên, khi tính MAPE, doanh thu của bánh mì chỉ sai 10% còn doanh thu của bánh kem sai 20%, cho thấy mô hình thực chất hiệu quả hơn trên nhóm có doanh thu lớn.

II.7. Median Absolute Error

Median Absolute Error (MedAE), tạm dịch là Sai số Tuyệt đối Trung vị, là một metric trong bài toán hồi quy tính toán sai số bằng cách lấy giá trị **median** (trung vị) của tất cả các sai số tuyệt đối, thay vì lấy giá trị trung bình như trong MAE.

Điểm đặc biệt và giá trị nhất của MedAE là **robust to outliers** (kháng cự mạnh mẽ với các giá trị ngoại lai). Nó trả lời cho câu hỏi: “Nếu bỏ qua những trường hợp dự đoán sai lệch bất thường, thì sai số điển hình của mô hình là bao nhiêu?”.

Nếu $\hat{y}_i$ là giá trị dự đoán của mẫu thứ i -th và y_i là giá trị thực tế tương ứng, công thức của sai số tuyệt đối trung vị MedAE được định nghĩa là:

$$\text{MedAE}(y, \hat{y}) = \text{median}(|y_1 - \hat{y}_1|, \dots, |y_n - \hat{y}_n|)$$

,trong đó:

- **median()** là hàm tính toán giá trị trung vị của một dãy số. **Giá trị trung vị** là số có vị trí nằm ở chính giữa của dãy số sau khi đã được sắp xếp.
- $|y_i - \hat{y}_i|$ là sai số tuyệt đối tại mẫu dữ liệu thứ i -th, với $i = 1, 2, \dots, n$.

Kết quả của MedAE là một giá trị trong khoảng $[0, +\infty)$, được diễn giải như sau:

- Giá trị của MedAE càng tiến đến gần 0, mô hình càng được xem là chính xác.

💡 **Ví dụ:** Giả sử trong một tuần, mô hình dự đoán doanh thu của hàng bánh có sai số nhỏ trong hầu hết các ngày (khoảng 450.000 VNĐ), nhưng lại có một sai số lớn đột biến vào cuối tuần là 7.000.000 VNĐ do sự kiện bất thường. Khi đánh giá, MAE sẽ bị sai số 7.000.000 kéo lên một con số rất cao (khoảng 1.350.000 VNĐ), trong khi MedAE sẽ bỏ qua giá trị đột biến này và chỉ ra con số 450.000 VNĐ.

⚠️ **Lưu ý:** Tuy nhiên, ở một số trường hợp khác như dự báo rủi ro tài chính, việc bỏ qua thông tin về sai số lớn có thể gây ra tổn thất nghiêm trọng. Khi đó, với việc phát hiện sai số lớn được ưu tiên, MSE sẽ trở thành lựa chọn tốt hơn

III. Thực hành

Trong phần này, để hiểu rõ hơn về các ứng dụng của từng metric, chúng ta sẽ áp dụng các metrics trong bài toán hồi quy vào một ví dụ cụ thể để so sánh và lựa chọn ra mô hình hồi quy tốt nhất. Từ đó, ta sẽ có cái nhìn tổng quan hơn về tầm quan trọng trong việc lựa chọn các metrics này.

III.1. Mô tả bài toán

Giả sử, chúng ta có một tập dữ liệu nhỏ về giá xe ô tô đã qua sử dụng của một doanh nghiệp AI trong vòng 5 năm gần nhất.

Bảng 2: Kết quả dự đoán giá xe của 3 mô hình Regression so với kết quả thực tế.

ID Xe	Năm SX	Km đã đi (Km)	Giá thực tế (triệu VNĐ)	Model A (triệu VNĐ)	Model B) (triệu VNĐ))	Model C (triệu VNĐ)
1	2022	10,000	750	740	780	755
2	2021	25,000	680	690	650	675
3	2020	50,000	550	560	520	545
4	2022	15,000	720	710	750	725
5	2019	80,000	450	460	420	455
6	2018	120,000	350	340	380	345

Q Phân tích dữ liệu ban đầu

- Giá thực tế là giá bán gốc của xe ô tô cũ, được đặt giá trị chuẩn để đánh giá.
- Mô hình A là kết quả dự đoán của mô hình Regression với cấu hình thứ nhất.
- Mô hình B là kết quả dự đoán của mô hình Regression với cấu hình thứ hai.
- Mô hình C là kết quả dự đoán của mô hình Regression với cấu hình thứ ba.

Yêu cầu bài toán: Từ **Bảng 3**, đã cho, hãy thực hiện tính toán các **Evaluation metrics** cho 3 mô hình A, B, C và đưa ra nhận xét để tìm ra mô hình hồi quy (Regression) hoạt động hiệu quả nhất:

- R^2 Score.
- Mean Absolute Error (MAE).
- Mean Squared Error (MSE).
- Mean Squared Logarithmic Error (MSLE).
- Mean Absolute Percentage Error (MAPE).
- Median Absolute Error (MedAE).

III.2. Lời giải

Để bắt đầu quá trình tính toán, trước hết chúng ta lập bảng phân tích các sai số riêng lẻ tại từng điểm dữ liệu ***i*-th** thông qua công thức:

$$e_i = y_i - \hat{y}_i, \quad i = 1, 2, \dots, n_{\text{samples}}.$$

Bảng 3: Bảng sai số riêng lẻ của từng mô hình.

Giá thực tế (y_i)	Mô hình A (e_i^A)	Mô hình B (e_i^B)	Mô hình C (e_i^C)
750	10	-30	-5
680	-10	30	5
550	-10	30	5
720	10	-30	-5
450	-10	30	-5
350	10	-30	5

Bảng sai số này sẽ hỗ trợ cho việc tính toán các metrics như R^2 , MAE, MSE, MAPE và MedAE khi những metrics này đều có điểm chung là thực hiện các phép biến đổi toán học trực tiếp trên các giá trị sai số $e_i = y_i - \hat{y}_i$, từ đó tránh sự lặp lại không cần thiết ở mỗi bước.

III.2.1. Tính toán bằng bảng R^2 Score

Bước 1: Tính giá trị trung bình $\bar{y}$

$$\begin{aligned} \bar{y} &= \frac{1}{n} \sum_{i=1}^n y_i = \frac{1}{6} (y_1 + y_2 + y_3 + y_4 + y_5 + y_6) \\ &= \frac{1}{6} \times (750 + 680 + 550 + 720 + 450 + 350) = \frac{3500}{6} = 583.33 \text{ (triệu VNĐ)} \end{aligned}$$

Bước 2: Tính SST (Total Sum of Squares)

$$\begin{aligned} \text{SST} &= \sum_{i=1}^n (y_i - \bar{y})^2 = (y_1 - \bar{y})^2 + (y_2 - \bar{y})^2 + \dots + (y_6 - \bar{y})^2 \\ &= (750 - 583.33)^2 + (680 - 583.33)^2 + \dots + (350 - 583.33)^2 = 129135.12 \end{aligned}$$

Bước 3: Tính SSR cho từng mô hình

Tổng bình phương sai số phần dư (Sum of Squared Residuals - SSR) được tính theo công thức:

$$\text{SSR} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n e_i^2$$

Từ các giá trị **sai số** e_i đã tính trong **Bảng 2**. ở trên, ta có SSR:

$$SSR_A = \sum_{i=1}^6 (y_i - \hat{y}_{iA})^2 = \sum_{i=1}^6 (e_{iA})^2 = 10^2 + (-10)^2 + (-10)^2 + 10^2 + (-10)^2 + 10^2 = 600$$

$$SSR_B = \sum_{i=1}^6 (y_i - \hat{y}_{iB})^2 = \sum_{i=1}^6 (e_{iB})^2 = (-30)^2 + 30^2 + 30^2 + (-30)^2 + 30^2 + (-30)^2 = 5400$$

$$SSR_C = \sum_{i=1}^6 (y_i - \hat{y}_{iC})^2 = \sum_{i=1}^6 (e_{iC})^2 = (-5)^2 + 5^2 + 5^2 + (-5)^2 + (-5)^2 + 5^2 = 150$$

Bước 4: Tính R^2 cho từng mô hình Hệ số xác định R^2 được tính theo công thức: $R^2 = 1 - \frac{SSR}{SST}$
 Áp dụng công thức trên cho từng mô hình:

$$R_A^2 = 1 - \frac{SSR_A}{SST} = 1 - \frac{600}{129135.12} = 0.9954$$

$$R_B^2 = 1 - \frac{SSR_B}{SST} = 1 - \frac{5400}{129135.12} = 0.9582$$

$$R_C^2 = 1 - \frac{SSR_C}{SST} = 1 - \frac{150}{129135.12} = 0.9988$$

III.2.2. Tính toán bằng MAE Score

Ta áp dụng công thức của MAE đã được định nghĩa:

$$MAE(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} |y_i - \hat{y}_i| = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} |e_i|$$

Từ các giá trị **sai số** e_i đã tính trong **Bảng 3**. ở trên, MAE cho từng mô hình là:

$$\begin{aligned} MAE_A &= \frac{1}{6} \sum_{i=1}^6 |y_i - \hat{y}_{iA}| = \frac{1}{6} \sum_{i=1}^6 |e_{iA}| \\ &= \frac{1}{6} (|10| + |-10| + |-10| + |10| + |-10| + |10|) = \frac{60}{6} = 10.00 \\ MAE_B &= \frac{1}{6} \sum_{i=1}^6 |y_i - \hat{y}_{iB}| = \frac{1}{6} \sum_{i=1}^6 |e_{iB}| \\ &= \frac{1}{6} (|-30| + |30| + |30| + |-30| + |30| + |-30|) = \frac{180}{6} = 30.00 \\ MAE_C &= \frac{1}{6} \sum_{i=1}^6 |y_i - \hat{y}_{iC}| = \frac{1}{6} \sum_{i=1}^6 |e_{iC}| \\ &= \frac{1}{6} (|-5| + |5| + |5| + |-5| + |-5| + |5|) = \frac{30}{6} = 5.00 \end{aligned}$$

III.2.3. Tính toán bằng MSE Score

Ta áp dụng công thức của MSE đã được định nghĩa:

$$\text{MSE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} (y_i - \hat{y}_i)^2 = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} e_i^2$$

Từ các giá trị sai số e_i đã tính trong **Bảng 3** ở trên, MSE cho từng mô hình là:

$$\begin{aligned} \text{MSE}_A &= \frac{1}{6} \sum_{i=1}^6 (y_i - \hat{y}_{iA})^2 = \frac{1}{6} \sum_{i=1}^6 (e_{iA})^2 \\ &= \frac{1}{6} (10^2 + (-10)^2 + (-10)^2 + 10^2 + (-10)^2 + 10^2) = \frac{600}{6} = 100.00 \\ \text{MSE}_B &= \frac{1}{6} \sum_{i=1}^6 (y_i - \hat{y}_{iB})^2 = \frac{1}{6} \sum_{i=1}^6 (e_{iB})^2 \\ &= \frac{1}{6} ((-30)^2 + 30^2 + 30^2 + (-30)^2 + 30^2 + (-30)^2) = \frac{5400}{6} = 900.00 \\ \text{MSE}_C &= \frac{1}{6} \sum_{i=1}^6 (y_i - \hat{y}_{iC})^2 = \frac{1}{6} \sum_{i=1}^6 (e_{iC})^2 \\ &= \frac{1}{6} ((-5)^2 + 5^2 + 5^2 + (-5)^2 + (-5)^2 + 5^2) = \frac{150}{6} = 25.00 \end{aligned}$$

III.2.4. Tính toán bằng MSLE Score

Ta áp dụng công thức của MSLE đã được định nghĩa:

$$\text{MSLE} = \frac{1}{n} \sum_{i=1}^n (\log(1 + y_i) - \log(1 + \hat{y}_i))^2 = \frac{1}{n} \sum_{i=1}^n (e'_i)^2$$

trong đó, e'_i biểu diễn sai số logarit được định nghĩa như sau:

$$e'_i = \log(1 + y_i) - \log(1 + \hat{y}_i), \quad i = 1, 2, \dots, n$$

Bảng 4. dưới đây trình bày thành phần sai số logarit bình phương $(e'_i)^2$ cho từng mô hình trên tất cả các điểm dữ liệu:

Bảng 4: Sai số Logarit Bình phương của từng mô hình			
Giá thực tế (y_i)	$(e'^A_i)^2$	$(e'^B_i)^2$	$(e'^C_i)^2$
750	0.00018	0.00155	0.00004
680	0.00021	0.00206	0.00005
550	0.00033	0.00318	0.00008
720	0.00020	0.00166	0.00005
450	0.00049	0.00473	0.00012
350	0.00083	0.00659	0.00021
Tổng (Σ)	0.00224	0.01977	0.00055

Từ bảng tính toán trên, MSLE cho từng mô hình được tính như sau:

$$\begin{aligned} \text{MSLE}_A &= \frac{1}{6} \times 0.00224 = 0.000373 \\ \text{MSLE}_B &= \frac{1}{6} \times 0.01977 = 0.003295 \\ \text{MSLE}_C &= \frac{1}{6} \times 0.000055 = 0.000092 \end{aligned}$$

III.2.5. Tính toán bằng MAPE Score

Ta áp dụng công thức MAPE đã được định nghĩa:

$$\text{MAPE}(y, \hat{y}) = 100 \times \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{\max(\epsilon, |y_i|)} = 100 \times \frac{1}{n} \sum_{i=1}^n \frac{|e_i|}{\max(\epsilon, |y_i|)}$$

với ϵ là một số thực dương rất nhỏ để tránh lỗi chia cho 0. Trong bài toán này, vì tất cả các giá trị y_i đều lớn hơn 0, ta có $\max(\epsilon, |y_i|) = |y_i| = y_i$.

Dựa trên dữ liệu đã cho, MAPE cho từng mô hình là:

$$\begin{aligned} \text{MAPE}_A &= 100 \times \frac{1}{6} \sum_{i=1}^6 \frac{|y_i - \hat{y}_{iA}|}{y_i} = 100 \times \frac{1}{6} \sum_{i=1}^6 \frac{|e_i^A|}{y_i} \\ &= 100 \times \frac{1}{6} \left(\frac{10}{750} + \frac{10}{680} + \frac{10}{550} + \frac{10}{720} + \frac{10}{450} + \frac{10}{350} \right) \approx 100 \times \frac{1}{6} \times 0.1109 \approx 1.85\% \end{aligned}$$

$$\begin{aligned} \text{MAPE}_B &= 100 \times \frac{1}{6} \sum_{i=1}^6 \frac{|y_i - \hat{y}_{iB}|}{y_i} = 100 \times \frac{1}{6} \sum_{i=1}^6 \frac{|e_i^B|}{y_i} \\ &= 100 \times \frac{1}{6} \left(\frac{30}{750} + \frac{30}{680} + \frac{30}{550} + \frac{30}{720} + \frac{30}{450} + \frac{30}{350} \right) \approx 100 \times \frac{1}{6} \times 0.3327 \approx 5.55\% \end{aligned}$$

$$\begin{aligned} \text{MAPE}_C &= 100 \times \frac{1}{6} \sum_{i=1}^6 \frac{|y_i - \hat{y}_{iC}|}{y_i} = 100 \times \frac{1}{6} \sum_{i=1}^6 \frac{|e_i^C|}{y_i} \\ &= 100 \times \frac{1}{6} \left(\frac{5}{750} + \frac{5}{680} + \frac{5}{550} + \frac{5}{720} + \frac{5}{450} + \frac{5}{350} \right) \approx 100 \times \frac{1}{6} \times 0.0555 \approx 0.92\% \end{aligned}$$

III.2.6. Tính toán bằng MedAE Score

MedAE được tính bằng cách tìm giá trị trung vị (số nằm giữa) của một dãy các sai số tuyệt đối đã được sắp xếp. Công thức có thể được biểu diễn như sau:

$$\text{MedAE}(y, \hat{y}) = \text{median}(|y_1 - \hat{y}_1|, |y_2 - \hat{y}_2|, \dots, |y_n - \hat{y}_n|) = \text{median}(|e_1|, |e_2|, \dots, |e_n|)$$

Để tính MedAE, đầu tiên ta cần liệt kê và sắp xếp lại dãy các sai số tuyệt đối $|e_i|$ cho từng mô hình:

- Đối với Mô hình A:

- Dãy sai số tuyệt đối là: $\{10, 10, 10, 10, 10, 10\}$.
- Dãy đã được sắp xếp. Vì có $n = 6$ giá trị (số chẵn), trung vị là trung bình cộng của hai giá trị ở vị trí thứ 3 và thứ 4.
- $\text{MedAE}_A = \frac{10+10}{2} = 10.00$ triệu VNĐ.
- **Đối với Mô hình B:**
 - Dãy sai số tuyệt đối là: $\{30, 30, 30, 30, 30, 30\}$.
 - $\text{MedAE}_B = \frac{30+30}{2} = 30.00$ triệu VNĐ.
- **Đối với Mô hình C:**
 - Dãy sai số tuyệt đối là: $\{5, 5, 5, 5, 5, 5\}$.
 - $\text{MedAE}_C = \frac{5+5}{2} = 5.00$ triệu VNĐ.

⚠ Lưu ý: Trong bài toán này, do sai số của mỗi mô hình là không đổi trên tất cả các điểm dữ liệu (ví dụ: Mô hình A luôn sai 10, Mô hình B luôn sai 30), nên không có giá trị outliers. Vì vậy, kết quả của MedAE cho ra giống hệt với MAE.

Kết luận

Bảng 5: Tổng hợp các metrics của ba mô hình hồi quy.

Metrics	Mô hình A	Mô hình B	Mô hình C
R² Score	0.9954	0.9582	0.9988
MAE (triệu VNĐ)	10.00	30.00	5.00
MSE (triệu VNĐ)²	100.00	900.00	25.00
MSLE	0.000373	0.003295	0.000092
MAPE (%)	1.85	5.55	0.92
MedAE (triệu VNĐ)	10.00	30.00	5.00

Như thể hiện rõ trong **Bảng 5**, mô hình C hoàn toàn vượt trội so với hai mô hình còn lại:

- **R² = 0.9988:** Giải thích được 99.88% sự biến thiên của dữ liệu, cho thấy mô hình có độ phù hợp gần như hoàn hảo.
- **MAE = 5.00:** Sai số trung bình chỉ là 5 triệu VNĐ cho mỗi chiếc xe, một mức chênh lệch rất nhỏ và có thể chấp nhận được trong kinh doanh.
- **MAPE = 0.92%:** Sai số dự đoán trung bình chưa tới 1% so với giá bán thực tế của xe, thể hiện độ chính xác tương đối vượt trội.
- **MSE = 25.00:** Mức sai số bình phương rất thấp, là một metric mạnh mẽ cho thấy rằng mô hình hoạt động rất ổn định và không tạo ra những sai số lớn bất thường (outliers).

Do đó, mô hình C là lựa chọn tối ưu trong số ba mô hình được đề xuất để triển khai cho bài toán dự đoán giá xe ô tô cũ.

IV. Câu hỏi trắc nghiệm

- Đâu là nhận định đúng nhất khi nói về MAE và MSE trong đánh giá mô hình hồi quy?
 - MAE ít nhạy cảm với các outliers hơn MSE.
 - MSE “trừng phạt” các sai số lớn nặng nề hơn MAE do sử dụng phép tính bình phương.
 - MAE có cùng đơn vị với biến mục tiêu, trong khi của MSE là bình phương đơn vị của mục tiêu.
 - MSE luôn cho giá trị lớn hơn MAE trong mọi trường hợp.
- Tại sao trong bài toán Regression với dữ liệu có outliers, việc so sánh R^2 và MAE có thể đưa ra kết luận mâu thuẫn về chất lượng mô hình?
 - R^2 là một chỉ số tương đối (thường từ 0-1), trong khi MAE là chỉ số tuyệt đối.
 - MAE nhạy cảm với outliers hơn R^2 vì nó tính trực tiếp trên giá trị sai số.
 - R^2 rất nhạy cảm với outliers, trong khi MAE ít nhạy cảm hơn.
 - R^2 chỉ có thể dùng cho bài toán tuyến tính còn MAE có thể dùng cho đa số.

Bảng 6: Điểm số thực tế và dự đoán của học sinh.

ID	Giờ học		Giờ ngủ		Điểm thực tế		Model A		Model B		Model C	
					Toán	Anh	Toán	Anh	Toán	Anh	Toán	Anh
1	8	7			92	88	90	90	94	85	91	89
2	7	8			85	82	87	80	83	84	86	83
3	6	6			78	75	80	78	76	73	79	76
4	5	7			72	70	75	72	70	68	73	71
5	4	5			65	62	68	65	63	60	66	63
6	3	6			58	55	60	58	56	53	59	56
7	2	4			52	48	55	52	50	46	53	49
8	1	5			45	42	48	45	43	40	46	43

Sử dụng bảng 5 trên để trả lời các câu hỏi 3-10:

- Tính MAE của Model A cho môn Toán với 5 học sinh đầu:
 - 2.50 điểm.
 - 3.00 điểm.
 - 2.75 điểm.
 - 2.40 điểm.
- Tính MSE của Model C cho môn tiếng Anh.
 - 1.00 điểm².

- (b) 1.25 điểm².
 (c) 0.75 điểm².
 (d) 1.50 điểm².
5. So sánh MAE giữa ba mô hình cho môn Toán, xếp hạng từ TỐT NHẤT đến TỆ NHẤT:
- (a) Model A (2.5) > Model B (2.0) > Model C (1.0).
 (b) Model C (1.0) > Model B (2.0) > Model A (2.5).
 (c) Model B (2.0) > Model C (1.0) > Model A (2.5).
 (d) Model A (2.5) > Model C (1.0) > Model B (2.0).
6. Cho điểm trung bình thực tế môn Anh là 65.25 điểm. Tính SST của môn tiếng Anh?
- (a) 1869.5.
 (b) 1650.0.
 (c) 2100.0.
 (d) 1750.0.
7. Tính MedAE của Model A cho môn Anh?
- (a) 2.50 điểm.
 (b) 3.00 điểm.
 (c) 2.75 điểm.
 (d) 3.25 điểm.
8. Model nào có xu hướng dự đoán CAO HƠN thực tế nhiều nhất cho môn Toán?
- (a) Cả ba mô hình đều có bias âm.
 (b) Model B (1/8 lần).
 (c) Model A và Model C (đều 7/8 lần).
 (d) Model A (7/8 lần).
9. Giả sử có thêm học sinh thứ 9 với điểm thực tế Toán = 30, Model B dự đoán = 60 (outlier error = 30). Khi đó MAE và MedAE của Model B sẽ thay đổi như thế nào?
- (a) MAE tăng từ 2.0 lên 5.1, MedAE vẫn = 2.0, cho thấy MedAE kháng cự outliers tốt hơn.
 (b) MAE và MedAE đều tăng như nhau vì cả hai đều bị ảnh hưởng bởi outliers.
 (c) MAE giảm, MedAE tăng do outlier có tác động ngược chiều.
 (d) Không thể kết luận được vì cần thêm thông tin về distribution.
10. Nếu tính R^2 Score cho Model C môn Anh, giá trị R^2 là?
- (a) $R^2 = 0.95$ (estimated).
 (b) $R^2 = 1 - \frac{1869.5}{8} = -232.69$.
 (c) $R^2 = \frac{8}{1869.5} = 0.0043$.
 (d) $R^2 = 1 - \frac{8}{1869.5} = 0.9957$.

V. Tài liệu tham khảo

- [1] C. Willmott et al., “Advantages of the mean absolute error (mae) over the root mean square error (rmse) in assessing average model performance”, *Climate Research*, vol. 30, p. 79, Dec. 2005. DOI: [10.3354/cr030079](https://doi.org/10.3354/cr030079).
- [2] A. de Myttenaere et al., “Mean absolute percentage error for regression models”, *Neurocomputing*, vol. 192, pp. 38–48, 2016, ISSN: 0925-2312. DOI: <https://doi.org/10.1016/j.neucom.2015.12.114>.
- [3] T. Hastie et al., “The elements of statistical learning: Data mining, inference, and prediction”, *Math. Intell.*, vol. 27, pp. 83–85, Nov. 2004. DOI: [10.1007/BF02985802](https://doi.org/10.1007/BF02985802).

Phụ lục

1. **Datasets:** Các file dataset được đề cập trong bài có thể được tải tại [đây](#).
2. **Hint:** Các file code gợi ý có thể được tải tại [đây](#).
3. **Solution:** Các file code cài đặt hoàn chỉnh và phần trả lời nội dung trắc nghiệm có thể được tải tại [đây](#).
4. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại [đây](#). Tất cả câu hỏi sẽ được trả lời trong vòng tối đa 4 tiếng.

AIO_QAs-Verified

🔒 Private group · 1.4K members



Hình 11: Hình ảnh group facebook AIO Q&A.